

Datenzentrierte Informatik

Prof. Dr. Elena Demidova

Arbeitsgruppe Data Science & Intelligente Systeme (DSIS)

Abteilung III: Informationssysteme und Künstliche Intelligenz
Institut für Informatik
Rheinische Friedrich-Wilhelms-Universität Bonn

WS 25/26



Maximum-Likelihood-Schätzung & Parametrische Klassifikation

Thematische Einordnung und Lernziele

- Thematische Einordnung:
 - Datenzentrierte Informatik → Maschinelles Lernen
- notwendige Vorkenntnisse:
 - Grundlagen der Wahrscheinlichkeitstheorie
- Lernziele:
 - Maximum-Likelihood-Methode
 - Maximum-Likelihood-Methode (MLE)
 - MLE für verschiedene Verteilungen (Bernoulli-Verteilung, Multinomialverteilung, Normalverteilung)
 - Parametrische Klassifikation
 - Diskriminanzfunktionen
 - Diskriminanzfunktion für Normalverteilung
- Vorlesung basiert auf Kapitel 4 in [1]

Verteilungen an Daten anpassen: Maximum-Likelihood-Methode



Maximum-Likelihood-Methode

Maximum-Likelihood-Methode (engl. Maximum Likelihood Estimation, MLE) (*R. A. Fisher, 1922*)

- Statistische Methode zur Schätzung von Modellparametern
- **Ziel:**
 - Parameter θ eines Modells so schätzen, dass die beobachteten Daten am wahrscheinlichsten sind
- **Input:**
 - Stichprobe $\mathcal{D} = \{x^1, \dots, x^n\}$ mit beobachteten Messungen
 - Modell $p(x|\theta)$ mit unbekannten Parametern θ
- **MLE-Grundidee:**
 - Wähle die Parameter θ so, dass die Wahrscheinlichkeit (“Likelihood”) der beobachteten Daten \mathcal{D} maximiert wird

Maximum-Likelihood-Methode: Intuition


- **Beispiel:** eine Stichprobe enthält die Messungen $\mathcal{D} = \{11, 8, 12, 9, 10\}$
- Wir nehmen eine Normalverteilung $\mathcal{N}(\mu, \sigma^2)$ an
 - Erwartungswert μ und Varianz σ^2 sind unbekannt
- Wir schätzen die Parameter der Verteilung (μ und σ^2)
 - Es ist unwahrscheinlich, dass $\mu = 20$ diese Stichprobenwerte erklärt
 - Welcher μ -Wert wäre plausibler?



Maximum-Likelihood-Methode: Intuition

- Stichprobe $\mathcal{D} = \{11, 8, 12, 9, 10\}$, Normalverteilung $\mathcal{N}(\mu, \sigma^2)$
 - Zu welchen Parameterwerten gehört diese Stichprobe?

Wahrscheinlichkeitsdichtefunktionen, $\mathcal{N}(\mu, \sigma^2)$



Maximum-Likelihood-Schätzung: Beispiel

Beispiel: MLE in der E-Mail-Klassifikation

- **Ziel:** Schätzung der Wahrscheinlichkeit p , dass eine E-Mail-Nachricht Werbung enthält
- **Vorgehen:**
 - Wähle eine zufällige Stichprobe \mathcal{D}
 - Beispiel: $N = 30$ E-Mail-Nachrichten
 - Überprüfe die Nachrichten in \mathcal{D}
 - Beispiel: Wir identifizieren 5 Werbenachrichten ($x^i = 1$)
- Wie lässt sich der Anteil der Werbenachrichten in der gesamten E-Mail-Kollektion schätzen?
 - Wir nehmen Bernoulli-Verteilung an
 - Wahrscheinlichkeitsfunktion:

$$P(x) = p^x(1-p)^{1-x}, x \in \{0, 1\}$$

- MLE-Schätzer für p bei der Bernoulli-Verteilung:

$$\hat{p} = \frac{\sum_i x^i}{N} = \frac{5}{30} = 0,17$$

Maximum-Likelihood-Schätzung

Ziel: eine parametrische Verteilung finden, die die gegebene Stichprobe “gut erklärt”

- **Input:**

- eine unabhängige und identisch verteilte (iid) Stichprobe $\mathcal{D} = \{x^i\}_{i=1}^N$
- wir nehmen an, dass die Instanzen x^i aus einer bekannten Wahrscheinlichkeitsdichte $p(x|\theta)$ stammen, die bis auf die Parameter θ definiert ist:

$$x^i \sim p(x|\theta)$$

- **Maximierung der Likelihood:**

- durch Variieren von θ erhalten wir unterschiedliche Wahrscheinlichkeitsdichten $p(x|\theta)$
- finde den Parameterwert $\hat{\theta}$, der die Wahrscheinlichkeit der Stichprobe \mathcal{D} maximiert

Likelihood-Funktion

- Likelihood-Funktion $l(\theta|\mathcal{D})$: Likelihood der Stichprobe \mathcal{D} als Funktion der Parameter θ
 - Stichprobe $\mathcal{D} = \{x^i\}_{i=1}^N$ ist gegeben
 - Parameter θ müssen geschätzt werden
- Likelihood der gesamten iid-Stichprobe \mathcal{D} als Produkt der einzelnen Datenpunkte:

$$l(\theta|\mathcal{D}) \equiv p(\mathcal{D}|\theta) = \prod_{i=1}^N p(x^i|\theta)$$

- Maximum-Likelihood-Schätzer für θ : Wir suchen den $\hat{\theta}$ -Wert, der die Likelihood für die Stichprobe \mathcal{D} maximiert:

$$\hat{\theta} = \arg \max_{\theta} l(\theta|\mathcal{D})$$

- $\hat{\cdot}$ (Zirkumflex) kennzeichnet einen Schätzer


Log-Likelihood-Funktion

Log-Likelihood-Funktion (engl. log likelihood function), $\mathcal{L}(\theta|\mathcal{D})$

- Logarithmus der Likelihood, definiert als:

$$\mathcal{L}(\theta|\mathcal{D}) \equiv \log l(\theta|\mathcal{D}) = \sum_{i=1}^N \log p(x^i|\theta)$$

- $\log(\cdot)$ wandelt das Produkt in eine Summe um
 - monotone Transformation, Maximum bleibt unverändert
 - Vorteil: vereinfacht die Berechnungen



Rechenregeln: $\log(u \cdot v) = \log(u) + \log(v)$

Maximum-Likelihood-Schätzer

- Maximum-Likelihood-Schätzer für θ :
 - Gegeben eine Stichprobe \mathcal{D} , suchen wir den Parameterwert $\hat{\theta}$, der die Log-Likelihood-Funktion $\mathcal{L}(\theta|\mathcal{D})$ maximiert
- Vorgehen:
 - Log-Likelihood-Funktion $\mathcal{L}(\theta|\mathcal{D})$ aufstellen
 - $\mathcal{L}(\theta|\mathcal{D})$ nach den Parametern θ ableiten
 - (bei mehreren Parametern partielle Ableitungen je Parameter)

$$\frac{\partial \mathcal{L}}{\partial \theta} = 0$$

- Die Gleichung nach θ auflösen, um den Schätzwert $\hat{\theta}$ zu erhalten
 - verifizieren, ob bei der Nullstelle ein Maximum vorliegt (2. Ableitung überprüfen)
- Wir betrachten MLE-Schätzer für einige Verteilungen
 - Bernoulli-Verteilung
 - Multinomialverteilung
 - Normalverteilung

Bernoulli-Verteilung


- Bernoulli-Verteilung (engl. Bernoulli distribution) beschreibt ein Zufallsexperiment mit genau zwei möglichen Ergebnissen:

$$X = \begin{cases} 1, & \text{Ereignis tritt ein, mit Wahrscheinlichkeit } p \\ 0, & \text{Ereignis tritt nicht ein, mit Wahrscheinlichkeit } 1 - p \end{cases}$$

- Beispiel: Klassifikation einer E-Mail-Nachricht x^i

$$X = \begin{cases} 1, & x^i \text{ ist Werbung} \\ 0, & x^i \text{ ist keine Werbung} \end{cases}$$

- Ziel: Schätzung des Parameters p der Bernoulli-Verteilung gegeben einer Stichprobe $\mathcal{D} = \{x^i\}_{i=1}^N$




Bernoulli-Verteilung

- Parameter p der Bernoulli-Verteilung ist die Wahrscheinlichkeit, dass das Ergebnis $X = 1$ eintritt:
 - $P(X = 1) = p$
 - $P(X = 0) = 1 - p$: Wahrscheinlichkeit des Nichteintretens
- Wahrscheinlichkeitsfunktion der Bernoulli-Verteilung:

$$P(x) = p^x(1 - p)^{1-x}, x \in \{0, 1\}$$

- Erwartungswert: $E[x] = p$
- Varianz: $Var(x) = p \cdot (1 - p)$
- Beispiele von Verteilungen bei verschiedenen p -Werten



Maximum-Likelihood-Schätzer für Bernoulli-Verteilung

- **Ziel:** Schätzung \hat{p} des **Parameters p** der Bernoulli-Verteilung mithilfe der Log-Likelihood-Funktion
 - Wahrscheinlichkeitsfunktion der Bernoulli-Verteilung:

$$P(x) = p^x(1-p)^{1-x}$$

- $\mathcal{D} = \{x^i\}_{i=1}^N$: eine iid-Stichprobe
- Log-Likelihood-Funktion $\mathcal{L}(p|\mathcal{D})$ für Bernoulli-Verteilung:

$$\begin{aligned}\mathcal{L}(p|\mathcal{D}) &= \log \prod_{i=1}^N p^{x^i} \cdot (1-p)^{1-x^i} \\ &= \sum_i x^i \cdot \log(p) + \left(N - \sum_i x^i \right) \cdot \log(1-p)\end{aligned}$$

- Interpretation:
 - $\sum_i x^i$ zählt, wie oft $X = 1$ in der Stichprobe \mathcal{D} vorkommt
 - $N - \sum_i x^i$ zählt, wie oft $X = 0$ vorkommt

Rechenregeln:

$$\log(u \cdot v) = \log(u) + \log(v); \log(u^v) = v \cdot \log(u)$$

Maximum-Likelihood-Schätzer für Bernoulli-Verteilung

- Log-Likelihood-Funktion $\mathcal{L}(p|\mathcal{D})$ für Bernoulli-Verteilung:

$$\mathcal{L}(p|\mathcal{D}) = \sum_i x^i \cdot \log(p) + \left(N - \sum_i x^i \right) \cdot \log(1-p)$$

- Um den Wert \hat{p} für die Maximierung der $\mathcal{L}(p|\mathcal{D})$ zu finden, wird \mathcal{L} nach dem Parameter p differenziert und nach p aufgelöst:

$$\frac{\partial \mathcal{L}}{\partial p} = \frac{\sum_i x^i}{p} - \frac{N}{1-p} + \frac{\sum_i x^i}{1-p} = 0$$





- Wie kann man überprüfen, ob es sich bei dieser Nullstelle um ein Maximum handelt?

- Daraus ergibt sich die Schätzung für p :
$$\hat{p} = \frac{\sum_i x^i}{N}$$
 - Interpretation: Schätzung für p ist das Verhältnis der Anzahl der Ereignisse $X = 1$ zur Stichprobengröße N
 - In dem Beispiel: enthalten 17% der E-Mails in der Stichprobe Werbung, ist $\hat{p} = 0,17$

Rechenregeln: $\log(x)' = \frac{1}{x}$; $g(h(x))' = g'(h(x)) \cdot h'(x)$

Maximum-Likelihood-Methode: Bernoulli-Verteilung

- Bernoulli-Verteilung, Stichprobe $\mathcal{D} = \{x^i\}_{i=1}^N, x \in \{0, 1\}$
- $N = 100, \sum_i x^i = 80$



Multinomialverteilung

- **Multinomialverteilung** (engl. multinomial distribution): eine Verallgemeinerung der Bernoulli-Verteilung auf $K \geq 2$ mögliche, sich gegenseitig ausschließende Zustände
 - **Zufallsexperiment:** Ein Ereignis tritt in genau einem von K möglichen Zuständen auf
 - Beispiel: Klassifikation von Dokumenten in K Kategorien (z. B. Nachrichten, Werbung, Spam, usw.)
 - Jeder Zustand k hat eine Wahrscheinlichkeit p_k , wobei gilt:

$$\sum_{k=1}^K p_k = 1$$

- **Indikatorvariablen:** x_1, x_2, \dots, x_K , definiert durch:
$$x_k = \begin{cases} 1, & \text{wenn Zustand } k \text{ eintritt} \\ 0, & \text{sonst} \end{cases}$$
- Bei einem Experiment: $P(x_1, x_2, \dots, x_K) = \prod_{k=1}^K p_k^{x_k}$


MLE für die Multinomialverteilung

- Wir führen N unabhängige Experimente mit den Ergebnissen $\mathcal{D} = \{\mathbf{x}^i\}_{i=1}^N$ durch, wobei:
 - $x_k^i = \begin{cases} 1, & \text{falls im Experiment } i \text{ der Zustand } k \text{ eintritt} \\ 0, & \text{sonst} \end{cases}$
 - Es gilt: $\sum_k x_k^i = 1$, d.h., jedes Experiment führt zu genau einem Zustand
- **Maximum-Likelihood-Schätzer für p_k :**
$$\hat{p}_k = \frac{\sum_i x_k^i}{N}$$
- **Interpretation:**
 - \hat{p}_k ist die relative Häufigkeit des Auftretens von Zustand k in der Stichprobe
- **Beispiel:**
 - In einer Trainingsmenge: \hat{p}_k = Anteil der Instanzen der Klasse \mathcal{C}_k
 - jeder Zustand k kann als ein separates Bernoulli-Experiment betrachtet werden
 - jedes Experiment fällt in einen von K Zuständen

Normalverteilung (Gauß-Verteilung)

- Eine Normalverteilung (Gauß-Verteilung) (engl. normal (Gaussian) distribution) $\mathcal{N}(\mu, \sigma^2)$ ist eine kontinuierliche Wahrscheinlichkeitsverteilung
 - Sie ist parametrisiert durch:
 - Erwartungswert μ
 - Varianz σ^2
- Dichtefunktion der Normalverteilung:

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right), -\infty < x < \infty$$



Log-Likelihood-Funktion für die Normalverteilung

- Gegeben: Stichprobe $\mathcal{D} = \{x^i\}_{i=1}^N$ mit $x^i \sim \mathcal{N}(\mu, \sigma^2)$
 - Daten sind unabhängig und identisch verteilt und folgen einer Normalverteilung mit unbekanntem Erwartungswert μ und Varianz σ^2
- Log-Likelihood-Funktion beschreibt die Wahrscheinlichkeit, die beobachtete Stichprobe \mathcal{D} zu erhalten, basierend auf den Parametern μ und σ :

$$\begin{aligned}\mathcal{L}(\mu, \sigma | \mathcal{D}) &= \sum_{i=1}^N \log p(x^i | \mu, \sigma) \\ &= \sum_{i=1}^N \log \frac{1}{\sigma \sqrt{2\pi}} \exp\left(-\frac{(x^i - \mu)^2}{2\sigma^2}\right) \\ &= -\frac{N}{2} \log(2\pi) - N \log \sigma - \frac{\sum_i (x^i - \mu)^2}{2\sigma^2}\end{aligned}$$

Rechenregeln:

$$\log(u \cdot v) = \log(u) + \log(v); \log\left(\frac{u}{v}\right) = \log(u) - \log(v); \log(u^v) = v \cdot \log(u)$$

Maximum-Likelihood-Schätzer für Normalverteilung

- **Ziel:** Bestimme den Maximum-Likelihood-Schätzer (MLE) für die Parameter μ und σ^2 der Normalverteilung gegeben eine Stichprobe $\mathcal{D} = \{x^i\}_{i=1}^N$, wobei $x^i \sim \mathcal{N}(\mu, \sigma^2)$
 - **Vorgehen:** Maximiere die Log-Likelihood-Funktion durch Nullsetzen der partiellen Ableitungen:

$$\mathcal{L}(\mu, \sigma | \mathcal{D}) = -\frac{N}{2} \log(2\pi) - N \log \sigma - \frac{\sum_i (x^i - \mu)^2}{2\sigma^2}$$

$$\frac{d\mathcal{L}}{d\mu} = \frac{1}{\sigma^2} \sum_i (x^i - \mu) = 0$$

- $\frac{d\mathcal{L}}{d\sigma} = 0$ analog, s. nächste Folie
- Auflösen nach den Parametern μ und σ^2 auf
- **MLE für den Erwartungswert μ** ist der empirische Mittelwert, d. h. der Mittelwert der gemessenen Werte x^i in der Stichprobe:

$$\hat{\mu} = \frac{\sum_i x^i}{N} = \bar{x}$$

Maximum-Likelihood-Schätzer für Normalverteilung

- Um den Maximum-Likelihood-Schätzer für die Varianz σ^2 zu bestimmen:
 - berechnen wir die partielle Ableitung der Log-Likelihood-Funktion nach dem Parameter σ :

$$\mathcal{L}(\mu, \sigma | \mathcal{D}) = -\frac{N}{2} \log(2\pi) - N \log \sigma - \frac{\sum_i (x^i - \hat{\mu})^2}{2\sigma^2}$$

$$\frac{d\mathcal{L}}{d\sigma} = -\frac{N}{\sigma} + \frac{1}{\sigma^3} \sum_i (x^i - \hat{\mu})^2 = 0$$

- und lösen nach σ^2 auf
- MLE für die Varianz σ^2 ist die Stichprobenvarianz, d. h. die mittlere quadratische Abweichung der gemessenen Werte x^i vom empirischen Mittelwert \bar{x} :

$$\hat{\sigma}^2 = s^2 = \frac{1}{N} \sum_i (x^i - \bar{x})^2$$

Rechenregeln: $\log(x)' = \frac{1}{x}$; $(x^n)' = n \cdot x^{n-1}$

Maximum-Likelihood-Schätzer für Normalverteilung

- Stichprobenvarianz

$$s^2 = \frac{1}{N} \sum_i (x^i - \bar{x})^2$$

ist ein verzerrter Schätzer für die Populationsvarianz σ^2 , weil er systematisch σ^2 unterschätzt

- Verzerrung des Schätzers: systematische Abweichung des geschätzten Wertes σ^2 von Erwartungswert $E[s^2]$ ¹

$$E[s^2] = \frac{N-1}{N} \cdot \sigma^2 \neq \sigma^2$$

- verzerrungsfreier Schätzer der Populationsvarianz:



$$\hat{\sigma}_{unbiased}^2 = \frac{1}{N-1} \sum_i (x^i - \bar{x})^2 = \frac{N}{N-1} s^2$$

- Wenn N sehr groß ist, ist der Unterschied unbedeutend
 - d. h. s^2 ist asymptotisch verzerrungsfreier Schätzer

¹s. Seite 74 in [1] für die Berechnung

Maximum-Likelihood-Methode: Beispiel

- Stichprobe $\mathcal{D} = \{11, 8, 12, 9, 10\}$, Normalverteilung



- MLE für μ : Stichprobenmittelwert

$$\frac{d\mathcal{L}}{d\mu} = \frac{1}{\sigma^2} \sum_i (x^i - \mu) = 0$$

$$\hat{\mu} = \frac{\sum_i x^i}{N} = \bar{x} = 10$$

- MLE für σ^2 : Stichprobenvarianz

$$\frac{d\mathcal{L}}{d\sigma} = -\frac{N}{\sigma} + \frac{1}{\sigma^3} \sum_i (x^i - \hat{\mu})^2 = 0$$

$$\hat{\sigma}^2 = s^2 = \frac{1}{N} \sum_i (x^i - \bar{x})^2 = 2, 5^2$$

Parametrische Klassifikation

Parametrische Klassifikation

Bei der **parametrischen Klassifikation** (engl. parametric classification) gehen wir davon aus, dass die Daten innerhalb jeder Klasse \mathcal{C}_k einer bestimmten Verteilung folgen, die durch Parameter beschrieben wird

- Schätzung der Parameter:
 - Wir nutzen die Trainingsdaten, um die Parameter für
 - die a-priori-Wahrscheinlichkeiten $P(\mathcal{C}_k)$
 - die Klassen-Likelihoods $p(\mathbf{x}|\mathcal{C}_k)$ zu schätzen
 - dazu wird häufig MLE verwendet
- Berechnung der a-posteriori-Wahrscheinlichkeiten
 - mit dem Satz von Bayes
- Diskriminanten:
 - Für jede Klasse \mathcal{C}_k berechnen wir die Diskriminante
 - a-posteriori-Wahrscheinlichkeiten oder deren Logarithmen
 - Wir wählen die Klasse mit der höchsten Diskriminante

Parametrische Klassifikation: Diskriminanzfunktion

- Die a-posteriori-Wahrscheinlichkeit der Klasse \mathcal{C}_k errechnen wir als:

$$P(\mathcal{C}_k|x) = \frac{p(x|\mathcal{C}_k)P(\mathcal{C}_k)}{p(x)} = \frac{p(x|\mathcal{C}_k)P(\mathcal{C}_k)}{\sum_{j=1}^K p(x|\mathcal{C}_j)P(\mathcal{C}_j)}$$

- Die Diskriminanzfunktion:

$$g_k(x) = p(x|\mathcal{C}_k)P(\mathcal{C}_k)$$

- Äquivalent können wir die Log-Variante nutzen:

$$g_k(x) = \log p(x|\mathcal{C}_k) + \log P(\mathcal{C}_k)$$

Diskriminanzfunktion bei Normalverteilung

- Falls $p(x|\mathcal{C}_k)$ einer Normalverteilung unterliegt, dann gilt:
 - Klassen-Likelihood:

$$p(x|\mathcal{C}_k) = \frac{1}{\sigma_k \sqrt{2\pi}} \exp\left(-\frac{(x - \mu_k)^2}{2\sigma_k^2}\right)$$

- Diskriminanzfunktion:

$$\begin{aligned} g_k(x) &= \log p(x|\mathcal{C}_k) + \log P(\mathcal{C}_k) \\ &= -\frac{1}{2} \log 2\pi - \log \sigma_k - \frac{(x - \mu_k)^2}{2\sigma_k^2} + \log P(\mathcal{C}_k) \end{aligned}$$

- Achtung: Normalität der Verteilung $p(x|\mathcal{C}_k)$ soll zuerst durch einen statistischen Test überprüft werden
 - z. B. Kolmogorov-Smirnov-Test, Chi-Quadrat-Test
 - ansonsten ist $g_k(x)$ in der Form nicht anwendbar!

Parametrische Klassifikation: Anwendungsbeispiel

- Anwendungsbeispiel:
 - Ein Autohaus verkauft $K = 3$ verschiedene Autotypen:
 - $\mathcal{C} = \{\mathcal{C}_1 = \text{Kompaktwagen}, \mathcal{C}_2 = \text{SUV}, \mathcal{C}_3 = \text{Sportwagen}\}$
 - zur Vereinfachung nehmen wir an, dass der einzige Faktor für die Kaufentscheidung ist das Jahreseinkommen des Kunden
 - Folgende Daten liegen vor:

	Kunde	Jahreseinkommen, T. EUR	Autotyp
Trainingsmenge	$Kunde_1$	80	Kompaktwagen
	$Kunde_2$	120	SUV
	$Kunde_3$	200	Sportwagen
	$Kunde_4$	100	SUV
	$Kunde_5$	300	Sportwagen
	$Kunde_6$	70	Kompaktwagen
	$Kunde_7$	75	Kompaktwagen
Testmenge	$Kunde_z$	90	?

Parametrische Klassifikation: Vorgehensweise

Vorgehensweise:

- Überprüfung der Verteilung der Merkmale (Einkommen) in jeder Klasse
 - aufgrund der Überprüfung gehen wir davon aus, dass diese der Normalverteilung folgen
- Modellierung der Klassen-Likelihoods:
 - wir approximieren die Klassen-Likelihoods $p(x|\mathcal{C}_k)$ durch die Normalverteilung $p(x|\mathcal{C}_k) \sim \mathcal{N}(\mu_k, \sigma_k^2)$
- Schätzung der Normalverteilungs-Parameter
 - wir schätzen Parameter der Normalverteilung für jede Klasse, $\hat{\mu}_k$ und $\hat{\sigma}_k^2$ anhand der Trainingsdaten \mathcal{D}
- Schätzung der a-priori-Wahrscheinlichkeiten
 - anhand der Trainingsdaten \mathcal{D}
- Berechnung der Diskriminanzfunktionen der Klassen $g_k(x)$
- Vorhersage: die Klasse, die die höchste $g_k(x)$ für x aufweist

Anwendungsbeispiel: Stichprobe

- Stichprobe: $\mathcal{D} = \{(\mathbf{x}^1, \mathbf{y}^1), (\mathbf{x}^2, \mathbf{y}^2), \dots, (\mathbf{x}^n, \mathbf{y}^n)\}$
 - $x \in \mathbb{R}$ ist **eindimensionale Eingabe**, entspricht dem Jahreseinkommen eines Kunden
 - $\mathbf{y} \in \{0, 1\}^K$ ist ein K -dimensionaler binärer Vektor

$$y_k^i = \begin{cases} 1, & \text{falls } x^i \in \mathcal{C}_k, \\ 0, & \text{falls } x^i \in \mathcal{C}_j, j \neq k \end{cases}$$

Anwendungsbeispiel: Parameterschätzung

- Für jede Klasse \mathcal{C}_k berechnen wir die Schätzungen für den Erwartungswert und Varianz basierend auf MLE für Normalverteilung:
 - Empirischer Mittelwert der Klasse \mathcal{C}_k :

$$\hat{\mu}_k = \frac{\sum_i x^i \cdot y_k^i}{\sum_i y_k^i}$$

- entspricht dem Mittelwert der Jahreseinkommen der Kunden in der Stichprobe, die einen Wagen der Klasse \mathcal{C}_k kaufen
- Varianz der Klasse \mathcal{C}_k :

$$\hat{\sigma}_k^2 = \frac{\sum_i (x^i - \hat{\mu}_k)^2 \cdot y_k^i}{\sum_i y_k^i}$$

- entspricht der mittleren quadratischen Abweichung der gemessenen Jahreseinkommen-Werte x^i in der Klasse \mathcal{C}_k vom empirischen Mittelwert der Klasse $\hat{\mu}_k$

Beispiel: Schätzung der a-priori-Wahrscheinlichkeiten

- Schätzung der a-priori-Wahrscheinlichkeiten der Klassen:

$$\hat{P}(\mathcal{C}_k) = \frac{\sum_i y_k^i}{N}$$

- entspricht dem Anteil der Kunden in der Stichprobe, die einen Wagen der Klasse \mathcal{C}_k kaufen

Beispiel: Diskriminanzfunktionen

- Wir nutzen die geschätzten Werte für die Schätzung der Diskriminanzfunktionen der Klassen $g_k(x)$

$$g_k(x) = -\frac{1}{2} \log 2\pi - \log \hat{\sigma}_k - \frac{(x - \hat{\mu}_k)^2}{2\hat{\sigma}_k^2} + \log \hat{P}(\mathcal{C}_k)$$

- $-\frac{1}{2} \log 2\pi$ ist eine Konstante, wird weggelassen
- wenn a-priori-Werte der Klassen gleich sind, wird $\log \hat{P}(\mathcal{C}_k)$ ebenfalls weggelassen
- falls auch Varianzen gleich sind, gilt:

$$g_k(x) = -(x - \hat{\mu}_k)^2$$

- unter diesen Annahmen wird x der Klasse mit dem naheliegenden empirischen Mittelwert zugewiesen:

wähle \mathcal{C}_k , falls $|x - \hat{\mu}_k| = \min_j |x - \hat{\mu}_j|$

Parametrische Klassifikation: Beispiel

Kompaktwagen			SUV			Sportwagen		
$\hat{\mu}_1$	$\hat{\sigma}_1$	$\hat{P}(\mathcal{C}_1)$	$\hat{\mu}_2$	$\hat{\sigma}_2$	$\hat{P}(\mathcal{C}_2)$	$\hat{\mu}_3$	$\hat{\sigma}_3$	$\hat{P}(\mathcal{C}_3)$
75	4	0,42	110	5	0,29	250	50	0,29

- Welcher Klasse wird ein Kunde mit dem Jahreseinkommen 90 T.EUR zugewiesen?

Parametrische Klassifikation: Beispiel

Kompaktwagen			SUV			Sportwagen		
$\hat{\mu}_1$	$\hat{\sigma}_1$	$\hat{P}(\mathcal{C}_1)$	$\hat{\mu}_2$	$\hat{\sigma}_2$	$\hat{P}(\mathcal{C}_2)$	$\hat{\mu}_3$	$\hat{\sigma}_3$	$\hat{P}(\mathcal{C}_3)$
75	4	0,42	110	5	0,29	250	50	0,29

- Wir berechnen die Werte der Diskriminanzfunktionen $g_k(x)$ für den Kunden mit dem Einkommen $x = 90$ für jede Klasse

$$g_1(90) = -\log 4 - \frac{(90 - 75)^2}{2 \cdot 4^2} + \log 0,42 = -8,01$$

$$g_2(90) = -\log 5 - \frac{(90 - 110)^2}{2 \cdot 5^2} + \log 0,29 = -9,24$$

$$g_3(90) = -\log 50 - \frac{(90 - 250)^2}{2 \cdot 50^2} + \log 0,29 = -7,36$$

- Der Kunde wird der Klasse \mathcal{C}_3 zugewiesen
 - Ist das Ergebnis plausibel? Welche Faktoren führen dazu?

Fazit: Maximum-Likelihood-Schätzung & Parametrische Klassifikation

Die Studierenden sollen in der Lage sein

- Parametrische Klassifikation zu beschreiben und zu diskutieren
- Maximum-Likelihood-Methode zu beschreiben
- die Definition der Likelihood anzugeben
- einen Maximum-Likelihood-Schätzer für eine einfache Dichte analytisch berechnen
 - Bernoulli-Verteilung, Multinomialverteilung, Normalverteilung
- für eine gegebene Stichprobe eine geeignete Verteilung finden und anpassen
- Parametrische Klassifikation anzuwenden

Literatur und Vorlesungsfolien

Maschinelles Lernen:

- ① Ethem Alpaydin: „Maschinelles Lernen“. De Gruyter Studium. 2. Auflage, (2019).
- ② Aurélien Géron: „Praxiseinstieg Machine Learning mit Scikit-Learn, Keras und TensorFlow: Konzepte, Tools und Techniken für intelligente Systeme“. O'Reilly, 2. Auflage, (2020).

ML-Bücher sind auch elektronisch in der Bibliothek vorhanden!

<https://bonnus.ulb.uni-bonn.de/>

- Vorlesungsfolien: s. eCampus
 - Die Vorlesungsmaterialien, einschließlich aller Vorlesungsfolien, Übungsmaterialien und Prüfungsfragen, werden ausschließlich für die Teilnehmer*innen des Moduls "BA-INF 035 Datenzentrierte Informatik" an der Universität Bonn im WS 2025/2026 bereitgestellt. Die Weitergabe an Dritte, die Veröffentlichung und die Verbreitung der Vorlesungsmaterialien sind untersagt.